

Tarea 2 — Introducción a la Ciencia de Datos

2026

Grupo 12
Germán Astol
Santiago Tucci

1. Introducción

Este informe presenta el análisis de clasificación automática de artículos periodísticos según su medio de origen, utilizando el mismo subconjunto del dataset All the News 2.1 – Component One de la Tarea 1. El trabajo se divide en dos partes: la primera abarca la preparación de los datos y su representación numérica; la segunda, el entrenamiento y evaluación de modelos de clasificación.

Se trabajó en Python con las bibliotecas pandas y scikit-learn, sobre los tres medios con mayor cantidad de artículos: Reuters, The New York Times y CNBC.

Parte 1: Dataset y representación numérica de texto

1. Preparación del dataset

Se reutilizó la función `clean_text()` de la Tarea 1, que aplica las siguientes transformaciones al cuerpo del artículo: eliminación del encabezado de primera línea, conversión a minúsculas, eliminación de todo lo que no sea letra, número o espacio, y normalización de espacios múltiples.

Se seleccionaron los tres medios con mayor cantidad de artículos y se particionó el dataset en 70% entrenamiento y 30% test, usando muestreo estratificado con `random_state=42`, valor fijado arbitrariamente para garantizar la reproducibilidad de los resultados.

2. Verificación del balance de clases

La siguiente visualización confirma que la proporción de artículos de cada medio es idéntica en train y test, como resultado del muestreo estratificado. Reuters representa aproximadamente el 62% del total, mientras que The New York Times y CNBC representan cerca del 19% y 18% respectivamente




Figura 1 Balance de clases — Train vs Test

3. Representación Bag of Words

Bag of Words (BoW) convierte cada artículo en un vector de conteos: cada dimensión representa una palabra del vocabulario y el valor indica cuántas veces aparece en ese documento. Ejemplo:

Tabla 1

Ejemplo de representación Bag of Words

	"market"	"trump"	"family"
doc1	3	0	0
doc2	0	4	0
doc3	0	0	2

Tamaño de la matriz: $n_{\text{artículos}} \times n_{\text{palabras_vocabulario}}$. Con 30.000 artículos y 80.000 palabras únicas, la matriz tendría 2.400 millones de celdas.

Por qué es sparse: cada artículo usa apenas una fracción mínima del vocabulario. La mayoría de las celdas son cero, y almacenar sólo los valores no nulos reduce el uso de memoria drásticamente. Sin el dataset reducido, la matriz densa ocuparía 18 GB de RAM.

4. Representación TF-IDF

N-grama es una secuencia contigua de n palabras. Para la frase "the new york times": unigramas son ["the", "new", "york", "times"], bigramas son ["the new", "new york", "york times"]. Los bigramas capturan frases con significado propio que se pierden tratando cada palabra de forma independiente.

TF-IDF pondera cada palabra por qué tan distintiva es: aumenta con la frecuencia en el documento (TF) pero decrece si aparece en muchos documentos (IDF). Palabras comunes como "the" o "said" quedan con peso bajo; términos específicos de un medio o tema quedan con peso alto.

$$TF - IDF(t,d) = TF(t,d) \times \log(N / df(t))$$

Donde t es el término, d es el documento, N el número total de documentos y df(t) el número de documentos que contienen la palabra t.

5. Visualización PCA sobre TF-IDF

Se aplicó TruncatedSVD con 2 componentes sobre los vectores TF-IDF. Este algoritmo es equivalente a PCA aplicado a una matriz de datos no normalizados. Cuando tenemos una matriz de datos (TF-IDF) con gran porcentaje de ceros, al restarles la media rompería esa característica convirtiendo grandes cantidades de ceros en números decimales, haciendo el proceso computacional menos eficiente. SVD maneja las matrices esparcidas de forma nativa y eficiente sin alterar esos ceros.

Las configuraciones se representan en la Figura 2.




Figura 2 TruncatedSVD sobre TF-IDF — comparación de configuraciones

Base (sin stopwords, con IDF, unigramas): las tres nubes se superponen casi completamente. La varianza explicada (porcentaje de la información total del dataset captura cada componente principal) por las dos primeras componentes es muy baja (2.64% + 1.17%), lo que indica que el espacio TF-IDF es de muy alta dimensión.

Con stop_words: la separación visual no mejora significativamente, y la varianza explicada cae aún más (0.39% + 0.95%). Eliminar stopwords reduce el vocabulario pero no facilita la separación en solo 2 dimensiones.

Sin IDF: la varianza explicada sube notoriamente (11.35% + 5.04%) porque las palabras de alta frecuencia (comunes a todos los documentos) dominan las primeras componentes, haciendo que los clusters parezcan más separados. Sin embargo, esto es un artefacto: las palabras que más contribuyen son las más frecuentes en general, no las más discriminantes.

Bigramas: el vocabulario crece enormemente, la varianza explicada vuelve a ser baja (1.16% + 0.54%), y los clusters siguen solapados.

En todas las configuraciones, los tres medios no son linealmente separables con solo 2 componentes principales. La respuesta a si la separación se debe a estilo editorial, diferencias temáticas o pistas explícitas es probablemente las tres: Reuters tiene vocabulario de agencia muy distinto, The New York Times cubre política con un registro diferente al de CNBC, y las plantillas y URLs del medio no eliminadas en la limpieza actúan como pistas directas.

Se probó el mismo análisis pero agregando el filtrado de urls y plantillas al corpus, pero no se observan mejoras significativas en la separación, sugiriendo que las pistas explícitas están distribuidas en el cuerpo del texto y no concentradas en patrones removibles con regex.

La varianza explicada acumulada en las primeras 10 componentes es muy baja, alcanzando apenas el 4.4% en la componente 10:




Figura 3 Varianza explicada acumulada — primeras 10 componentes

Esto confirma que el espacio TF-IDF requiere muchas más dimensiones para capturar la estructura del corpus. Para clasificación, esto no es un problema porque los modelos lineales como Naive Bayes y Regresión Logística operan directamente en el espacio de alta dimensión.

Parte 2: Entrenamiento y Evaluación de Modelos

Para evaluar los modelos se utilizan accuracy, precision, recall y F1-score. Dado el desbalance entre clases, se reporta F1-macro como métrica principal, que promedia el F1 de cada clase sin ponderar por su tamaño.

1. Multinomial Naive Bayes

Se entrenó un clasificador Multinomial Naive Bayes sobre la representación BoW del conjunto de entrenamiento. Naive Bayes asume independencia entre features y estima la probabilidad de cada clase mediante el teorema de Bayes, usando las frecuencias de palabras como evidencia.




Figura 4 Matriz de confusión — Multinomial Naive Bayes (BoW)

El modelo obtiene un accuracy de 0.702. Sin embargo, los valores por clases revelan un problema generado por el desbalance.

Tabla 2

Precisión y recall del clasificador Multinomial Naive Bayes

Medio	Precisión	Recall
CNBC	1.000	0.010
Reuters	0.682	0.999
NYT	0.962	0.353

Estos valores se leen directamente de la matriz de confusión: la precisión de cada clase es el cociente entre los verdaderos positivos y el total de predicciones para esa clase (columna), mientras que el recall es el cociente entre los verdaderos positivos y el total de casos reales de esa clase (fila)

Problema con este resultado: el modelo predice casi todo como Reuters. Esto se debe a que fue entrenado sobre BoW sin IDF, y Reuters domina el 62% del corpus. El accuracy resultante es alto artificialmente.

Problema del accuracy con desbalance: si Reuters tuviera el 90% de los artículos, un modelo que predijera siempre Reuters obtendría 90% de accuracy sin aprender nada. En ese caso el accuracy es engañoso y conviene mirar precisión y recall por clase, o macro-F1.

2. Validación cruzada y búsqueda de hiperparámetros

Validación cruzada (k-fold CV): divide el conjunto de entrenamiento en k partes. En cada iteración usa k-1 folds para entrenar y el restante para validar, rotando hasta que cada fold fue validación una vez. El score final es el promedio de k evaluaciones, dando una estimación más robusta que una sola partición.

Se ejecutó GridSearchCV con 5-fold CV sobre el siguiente espacio de hiper-parámetros:

- `tfidf__ngram_range:` (1,1) o (1,2)
- `tfidf__use_idf:` True o False
- `nb__alpha:` 0.1, 0.5, 1.0




Figura 5 Distribución de $F1_macro$ por configuración (5-fold CV)

Dado que los datos presentan desbalance de hasta 3 veces más artículos de Reuters que de las otras publicaciones, se optó por optimizar F1-score en lugar de accuracy.

$$F1 = 2 \frac{\text{Precisión} * \text{Recall}}{\text{Precisión} + \text{Recall}}$$

Se elige esta métrica por encima de la de maximizar Accuracy para la búsqueda de hiperparámetros para evitar optimizar a la clase mayoritaria (Reuters), ignorando si el modelo destruye por completo el rendimiento en las clases minoritarias.

Usando F1-Score, por ser una **media armónica** entre la Precision y el Recall, el algoritmo se ve obligado a encontrar hiperparámetros que logren que ambas **métricas sean altas al mismo tiempo**.

La configuración con unigramas e IDF=True alcanza el mayor F1-score (~0.715), con muy baja variabilidad entre folds. Con el uso de bigramas la métrica cae considerablemente, probablemente porque el vocabulario crece demasiado para el tamaño del dataset. El parámetro alpha más bajo (0.1) tiende a dar mejores resultados.

Mejor configuración encontrada: 'nb__alpha': 0.1, 'tfidf__ngram_range': (1, 1), 'tfidf__use_idf': True

3. Entrenamiento final con el mejor modelo

Se re-entrenó el mejor modelo sobre todo el conjunto de entrenamiento (sin validación) y se evaluó en el conjunto de test:

Tabla 3

Métricas del mejor modelo Naive Bayes por clase

Medio	Precision	Recall	F1-score
CNBC	0.831	0.377	0.479
Reuters	0.820	0.942	0.877
The New York Times	0.760	0.803	0.781




Figura 6 Matriz de confusión — mejor modelo ($nb_alpha=0.1$, $ngram_range=(1,1)$, $use_idf=True$)

Accuracy final: 0.809. Buen desempeño general.

F1-score final: 0.712. El modelo clasifica bien Reuters (recall 0.94) y está bastante balanceado con los demás medios. La oportunidad está en CNBC donde su recall es de los más bajos.

Limitaciones de BoW/TF-IDF:

- Sin orden ni contexto: trata cada palabra de forma independiente, sin capturar sintaxis ni significado composicional.
- Sin semántica: "car" y "automobile" son palabras completamente distintas aunque signifiquen lo mismo.
- Vocabulario fijo: palabras fuera del vocabulario de entrenamiento se ignoran.
- Sensible a pistas explícitas: si el texto contiene el nombre del medio o su URL, el modelo las usa como atajo en lugar de aprender el estilo editorial real.

4. Comparativa de Modelos: Naive Bayes, Regresión Logística y KNN

Se entrenó una Regresión Logística y KNN con los mejores hiperparámetros para cada modelo.

En el caso de Regresión Logística, la mejor combinación es:

```
Logistic Regression: {'lr__C': 10.0, 'tfidf__ngram_range': (1, 2),
'tfidf__use_idf': False }
```

En el caso de KNN, la mejor combinación es:

```
KNN: {'knn__n_neighbors': 11, 'knn__weights': 'uniform',
'tfidf__ngram_range': (1, 1), 'tfidf__use_idf': False}
```




Figura 7 Comparación — Naive Bayes, Regresión Logística y KNN

El modelo de **Regresión Logística** es el mejor modelo de los tres, alcanzando un **accuracy** de 90.78%.

- No solo tiene la precisión general más alta, sino que su configuración óptima incluyó un **ngram_range: (1, 2)**. Esto significa que el modelo se benefició de

analizar tanto palabras sueltas como combinaciones de dos palabras (bigramas), lo que le permitió capturar mejor el contexto o las frases típicas de cada medio de comunicación.

- Los otros 2 modelos funcionaron mejor utilizando únicamente palabras individuales (`ngram_range: (1, 1)`), lo que sugiere que no logran aprovechar estructuras de texto más complejas tan bien como la Regresión Logística.

Tabla 4

Comparativa de modelos: Naive Bayes, Regresión Logística y KNN

Modelo	Accuracy	F1 score	Precisión CNBC	Recall CNBC
Naive Bayes	0.8090	0.7122	0.831	0.377
Logistic Regression	0.9078	0.8706	0.867	0.654
KNN	0.8049	0.7268	0.662	0.394

Aunque la precisión para CNBC usando LR (0.8706) es ligeramente menor que la de Naive Bayes, sigue siendo notablemente alta. La gran ventaja es que su *Recall* salta a un **65.4%**. Esto significa que logra capturar casi dos tercios de todas las noticias reales de CNBC, manteniendo una tasa de falsos positivos muy baja.

5. Cambio de medio de prensa: Reuters / NYT / People

Se reemplazó CNBC por People, introduciendo un desbalance de aproximadamente 6x entre Reuters (9.424 artículos) y People (1.528 artículos).




Figura 8 PCA — Reuters / NYT / People

En el mapa PCA, People queda más separado que CNBC en el conjunto original, lo que es esperable: su vocabulario de entretenimiento (family, love, told, really) es radicalmente distinto al vocabulario financiero y político de Reuters y NYT. Sin embargo, la separación sigue siendo parcial en solo 2 componentes.




Figura 9 Matriz de confusión — Reuters / NYT / People

Aplicando el modelo NB con los mejores hiperparámetros encontrados anteriormente, se observa que el desbalance afecta principalmente a People: el recall cae (353 bien clasificados vs 88 mal clasificados como NYT), lo que indica que el modelo sub-predice la clase minoritaria.

Sobre-muestreo y sub-muestreo: el sobre-muestreo (ej. SMOTE) genera ejemplos sintéticos de la clase minoritaria; el sub-muestreo descarta ejemplos de la mayoritaria. En texto, interpolar vectores TF-IDF no produce artículos reales, por lo que en la práctica suele preferirse ajustar `class_weight="balanced"` en el clasificador.

6. Técnica alternativa: Word Embeddings y BERT

Word Embeddings (Word2Vec, GloVe, FastText): representan cada palabra como un vector denso de dimensión fija (100–300) entrenado para que palabras con contextos similares queden cerca en el espacio vectorial. La diferencia clave respecto a TF-IDF es que captura similitud semántica: "car" y "automobile" quedan cerca. Para representar un artículo completo se promedia los vectores de sus palabras. Sin embargo, el vector promedio pierde el orden de las palabras.

Embeddings contextuales (BERT, RoBERTa): en lugar de asignar un vector fijo a cada palabra, generan una representación que depende del contexto completo de la oración. La palabra "bank" tiene un vector distinto en "river bank" y "central bank". Se obtienen de modelos pre entrenados y se pueden afinar (fine-tune) para la tarea específica.

En este problema esperaríamos mejoras concretas en la confusión Reuters/CNBC, que comparten vocabulario financiero pero tienen estilos distintos que un modelo contextual podría capturar mejor. La desventaja es el costo computacional: BERT requiere GPU y el fine-tuning tomaría horas, frente a segundos del pipeline TF-IDF + Naive Bayes.

7. Opcional: Clasificación a nivel de título

Se repitió el pipeline usando el título del artículo en lugar del cuerpo. Los títulos tienen entre 5 y 15 palabras, lo que le da muy poco vocabulario al modelo.

Tabla 5

Comparación de clasificación por artículo completo vs. solo título

Campo	Accuracy	f1-score
Artículo completo	0.8087	0.7122
Solo título	0.7270	0.5976

El accuracy cae 7.6 puntos al clasificar por título. La mayor diferencia se observa en The New York Times: el recall cae de 0.81 a 0.51, lo que indica que los títulos del NYT son difíciles de distinguir de Reuters con tan poco vocabulario. Reuters mantiene un recall relativamente alto (0.82) porque sus títulos tienen un estilo de agencia distintivo (formato de despacho rápido).

Conclusiones

El pipeline TF-IDF + Naive Bayes logra un accuracy de 0.81 en el conjunto de test, aunque con un recall bajo para CNBC (0.37) debido al solapamiento temático con Reuters. La Regresión Logística mejora el resultado general de accuracy a 0.90 y también mejora el F1-score a 0.87 reduciendo falsas detecciones.

KNN no supera significativamente a NB ni a RL en ninguna métrica.

El análisis PCA confirma que dos componentes son insuficientes para separar los medios: la varianza explicada acumulada por 10 componentes es apenas del 4.4%. Esto no afecta la clasificación porque los modelos lineales operan directamente en el espacio de alta dimensión.

Las principales fuentes de error son el solapamiento temático entre Reuters y CNBC, la presencia de pistas explícitas del medio no eliminadas en la limpieza, y las limitaciones inherentes a BoW para capturar contexto y semántica.

Declaración de uso de IA

Se utilizó Claude para ordenar el código.